


Análisis Predictivo

Tomás Odriozola

15/11/2023




Metodología





SELECCIÓN MODELOS Y VARIABLES





MODELO BASELINE

VARIABLES

```
Texto: []
Booleanas: ['isAdult']
Categóricas: ['titleType', 'genres_x']
Numéricas: ['numVotes', 'startYear', 'runtimeMinutes']
```

Total variables: 6

HIPERPARÁMETROS (DEFAULT)

RENDIMIENTO

SET VAL: R2=0.3384

CV: R2=0.3370

TEST: R2=0.3387

TRANSFORMACIONES



TUNEO TRANSFORMACIONES

XGBoost



TUNEO HIPERPARÁMETROS

XGBoost

Mejor rendimiento:

- n_stimators=300
- learning_rate=0.1
- max_depth=15
- gamma=0
- reg_lambda=4
- reg_alpha=0

```
param_grid = {
      'n_estimators': [200,300],
      'learning_rate': [0.01, 0.05, 0.1, 0.15],
      'max_depth': [10,15,20],
      'gamma': [0,1],
      'reg_lambda': [0,2,3,4,5,6],
      'reg_alpha': [0,2,4,6]
# original (params default): R2=0.3760569218349431
# n_estimators=300, learning_rate=0.1, max_depth=15: R2=0.4801958841065018
# n_estimators=300, learning_rate=0.1, max_depth=20: R2=0.4437767704181339
# n_estimators=300, learning_rate=0.1, max_depth=10: R2=0.4324150870449379
# n_estimators=300, learning_rate=0.01, max_depth=15: R2=0.43125924430238916
# n_estimators=300, learning_rate=0.05, max_depth=15: R2=0.4784382254299179
# n_estimators=300, learning_rate=0.15, max_depth=15: R2=0.47399591249717976
# gamma=1: R2=0.4626361466830732
# reg_lambda=0: R2=0.47350737850120417
# reg lambda=2: R2=0.48186454366058595
# reg_lambda=3: R2=0.48205758927716247
# reg_lambda=4: R2=0.48470948112372336
# reg lambda=5: R2=0.48102181212496053
# reg lambda=6: R2=0.4811903713017869
# reg_lambda=0, reg_alpha=2: R2=0.48176103621296706
# reg lambda=0, reg alpha=4: R2=0.482444530083027
# reg_lambda=0, reg_alpha=6: R2=0.4787888913108943
```



MEJOR MODELO

VARIABLES

```
Texto: []

Booleanas: ['isAdult', 'isOriginalTitle', 'adult', 'video']

Categóricas: ['titleType', 'genres_x', 'directors', 'writers', 'language', 'attributes', 'genres_y', 'original_
Numéricas: ['numVotes', 'startYear', 'endYear', 'runtimeMinutes', 'seasonNumber', 'episodeNumber', 'ordering',

Total variables: 27

_language', 'status']

'budget', 'popularity', 'revenue', 'runtime', 'cant_writers', 'cant_directors', 'cant_genres_x']
```

TRANSFORMACIONES

HIPERPARÁMETROS

RENDIMIENTO

SET VAL: R2=0.4886 CV: R2=0.4812

TEST: R2=0.4922



Probar con otros modelos además de XGBoost, RF y SVM.

POSIBLES MEJORAS

APLICAR MÁS MODELOS APLICAR
TRANSFORM.
BASADAS EN
MODELOS

Generar transformaciones de las variables basándose en la totalidad del registo (Regresión) u otros registros (KNN)

Ampliar la prueba de hiperparámetros aplicando GridSearch GRIDSEARCH EN LUGAR DE RANDOMIZED IMPLEMENTAR NUEVAS VARIABLES

Generar nuevas variables a partir de los datos existentes y/o hacer web scrapping para obtener nuevos datos



iMuchas Gracias!